

Лабораторна робота №3.

Проектування функції винагорода та політ до заданої точки

26 серпня 2026 р.

Мета

Навчитися будувати складену функцію винагорода для квадрокоптера й вимірювати внесок кожного доданка абляцією. Навчити політику польоту до заданої точки та розпізнавати погану винагороду за числами в логах.

Склад бригади і розподіл ролей

Робота виконується бригадою з трьох осіб. Кожен учасник відповідає за свою підсистему й захищає її окремо.

- **Учасник А — середовище і винагорода.** Реалізує середовище польоту до точки й складену винагороду, яка повертає і суму, і кожен доданок окремо; забезпечує вимикання будь-якого доданка нульовою вагою.
- **Учасник В — абляція.** Проводить шість абляційних експериментів, два з них із повним навчанням політики, і фіксує, що саме ламається в поведінці при вимиканні кожного доданка.
- **Учасник С — зіпсована винагорода.** Досліджує вагу штрафу за різкість керування й навмисно псує винагороду двома способами, показуючи, як політика експлуатує формулювання.

Інтеграційний крок виконують разом: усі запуски зводять в одну таблицю й формулюють, без яких доданків задача не розв'язується, а які змінюють лише манеру польоту.

Теоретичні відомості

Алгоритм максимізує суму винагород за епізод, і тільки її. Чого немає у винагороді, того для політики не існує, а записане з неправильною вагою виконується рівно настільки, наскільки вигідно. Винагорода і є постановкою задачі, тому помилку в ній не виправить довше навчання.

Стандартний набір доданків для польоту до точки має вигляд

$$r_t = -w_d \|p^* - p_t\| - w_\omega \|\omega_t\| - w_\theta (1 - R_{33}) - w_a \|a_t - a_{t-1}\| - w_c \mathbb{K}_{\text{crash}} + w_l \quad (1)$$

де p^* , p_t — цільова й поточна позиція, м; ω_t — кутова швидкість, рад/с; R_{33} — елемент матриці повороту (при рівному польоті $R_{33} = 1$, тому $(1 - R_{33})$ — відхилення від горизонту); a_t — дія: 4 числа СТБР (тяга і три кутові швидкості); $\mathbb{K}_{\text{crash}}$ — аварія: удар об підлогу чи стелю або нахил понад 1,2 рад. Базові ваги: $w_d = 1,00$, $w_\omega = 0,05$, $w_\theta = 0,50$, $w_a = 0,02$, $w_c = 10,0$, $w_l = 0,10$.

Головний внесок дає відстань до цілі, близько 74 % модуля суми. Решта доданків задає лише *манеру* польоту. Це формувальні доданки (**reward shaping**): у формі $F = \gamma\Phi(s_{t+1}) - \Phi(s_t)$ вони не змінюють оптимуму. Штраф за аварію коштує близько 100 кроків польоту, тобто двох секунд. Без бонусу за життя всі доданки від’ємні, і найвигідніше впасти одразу.

Погану винагороду видають три ознаки:

- **локальний оптимум**: плато далеко від очікуваного, при $w_c = 100$ апарат висить під стелею;
- **уникання епізоду**: епізод коротшає, бо бонус за життя замалий;
- **експлуатація щілини (reward hacking)**: сума росте, а задача не виконується. При $w_l = 1,0$ вигідніше простояти 400 кроків біля старту (+400), ніж летіти з 2 м (−150).

За самою сумою жодної з них не видно. Потрібен розклад на доданки.

Очікуваний ефект вимикання доданків

Вимкнено	Що станеться з політикою	Як це видно в числах
наближення, w_d	задачі немає	відстань не спадає між епізодами
кутова швидкість, w_ω	крутиться заради маневру	середня $\ \omega\ $ понад 3 рад/с
нахил, w_θ	різкі нахили	аварій більше, епізод коротший
різкість дій, w_a	«смикає» мотори	ривок дії більший у 3–5 разів
аварія, w_c	летить напролом	аварій 3–5 із 5, епізод < 120 кроків
бонус за життя, w_l	обірвати епізод вигідно	сума росте, епізод коротшає

Політика отримує 18 чисел про власний стан. Цей самий склад успадковує робота №4, де до нього додається блок сусідів, тому зафіксуйте його точно.

Блок	Компоненти	Розмір	Одиниці
Вектор на ціль	$p_{\text{goal}} - p$	3	м
Лінійна швидкість	v_x, v_y, v_z	3	м/с
Орієнтація	матриця повороту R	9	—
Кутова швидкість	p, q, r	3	рад/с
Разом		18	

Орієнтацію подають саме матрицею повороту, а не кутами Ейлера: кути мають розриви на $\pm 180^\circ$, і мережа на них зривається.

Корисні посилання для ознайомлення:

- [Batra та ін. Decentralized Control of Quadrotor Swarms](#) — звідки взято склад винагороди;
- [Ng, Harada, Russell. Policy Invariance Under Reward Transformations](#) — коли shaping не змінює оптимуму;
- [Amodei та ін. Concrete Problems in AI Safety](#) — розділ про reward hacking;
- [Kaufmann та ін. Champion-level drone racing using deep RL](#) — винагорода в реальних перегонах.

Порядок виконання

1. **[разом]** Реалізувати середовище польоту до точки й складену винагороду за формулою (1) так, щоб функція повертала і суму, і кожен доданок окремо. Передбачити вимикання будь-якого доданка нульовою вагою.
2. **[А]** Написати опорну ПД-політику й виконати опорний прогін із базовими вагами. Зберегти розклад винагороди за доданками як точку відліку.
3. **[В]** Провести абляцію: по черзі вимкнути кожен доданок і зафіксувати, що саме змінилося в поведінці та в числах. Два доданки на вибір дослідити з повним навчанням політики, решту — з опорною політикою.
4. **[С]** Дослідити вагу штрафу за різкість керування: обрати кілька значень і показати, як змінюються гладкість керування й час польоту.
5. **[С]** Зіпсувати винагороду щонайменше двома способами так, щоб політика почала експлуатувати формулювання. Для кожного випадку навести розклад за доданками й пояснити механізм.
6. **[разом]** Звести всі запуски в одну таблицю й сформулювати, без яких доданків задача не розв'язується, а які змінюють лише манеру польоту.
7. **[разом] Оформити ноутбук.** Зібрати роботу в один Jupyter-ноутбук: код кожного учасника у своїх комірках із короткими коментарями там, де це доречно. Обов'язково всередині: розклад винагороди за доданками, результати абляції, графіки для трьох значень ваги різкості й зведену таблицю запусків, а також висновки — три-п'ять тверджень із числами. Ноутбук має виконуватися від початку до кінця без ручних правок; у першій комірці вкажіть, хто з учасників за які комірки відповідав.

Контрольні запитання

1. Чому винагорода і є постановкою задачі?
2. Що станеться з політикою, якщо всі доданки від'ємні?
3. Чому відхилення від горизонту подають через R_{zz} , а не через кут?
4. Скільком крокам польоту відповідає штраф за аварію в 10 одиниць?
5. Що таке reward shaping і коли він не змінює оптимуму?
6. Чим небезпечне надто складне формулювання винагороди?
7. Винагорода росте, але апарат не летить до цілі: що перевірите?
8. Чому при зростанні w_a з 0,02 до 0,20 страждає час, а не точність?
9. Навіщо абляція, якщо якість вимірюється сумою винагороди?
10. Політика висить на місці. Яку вагу зміните першою і в який бік?