

Лабораторна робота №2.

Перша політика навчання з підкріпленням для висіння

25 серпня 2026 р.

Мета

Сформулювати задачу висіння нанодрона Crazyflie 2.1 як задачу навчання з підкріпленням: спостереження, дія, винагорода. Навчити політику алгоритмом PPO у середовищі `gym-pybullet-drones`, оцінити її на 20 епізодах за середньою віддачею й часткою успішних епізодів і порівняти з PID-регулятором із роботи №1.

Склад бригади і розподіл ролей

Робота виконується бригадою з трьох осіб. Кожен учасник відповідає за свою підсистему й захищає її окремо.

- **Учасник А — середовище навчання.** Реалізує середовище, сумісне з `Gymnasium`: простір спостережень, простір дій, умови дострокового завершення, обчислення нормованої віддачі.
- **Учасник В — навчання політики.** Запускає PPO, веде журнал у `TensorBoard`, фіксує криву навчання й характерні фази, повторює навчання на трьох зернах.
- **Учасник С — оцінювання і порівняння.** Пише критерій успіху, оцінює політику на 20 епізодах, порівнює її з PID-регулятором із роботи №1 і готує відео польоту.

Інтеграційний крок виконують разом: середовище учасника А приймає політику учасника В, після чого учасник С проганяє обидві стратегії на однакових початкових станах.

Теоретичні відомості

Політику реалізує нейромережа з двома шарами по 64 нейрони. Вона 50 разів на секунду отримує спостереження й видає дію. Спостереження складається з дев'яти чисел бортового фільтра Калмана: похибка висоти $z - z^*$ (м), швидкості v_z, v_x, v_y (м/с), крен і тангаж (рад), кутові швидкості p, q, r (рад/с). Дія *одна*: нормована тяга $u \in [0; 1]$. Кутове положення утримує бортовий PID із прошивки.

Фізична тяга дорівнює $u \cdot F_{\max}$, де $F_{\max} = 0,568$ Н (57,9 г-сили) при масі $m = 33$ г. Отже, при $u = 0,57$ апарат висить, при $u = 1,0$ набирає ≈ 7 м/с², при $u = 0$ вільно падає; навчена політика має тримати $u \approx 0,57$.

Винагороду нараховують на кожному кроці, тобто 50 разів на секунду:

$$r_t = -w_z |z_t - z^*| - w_v |v_{z,t}| - w_u |u_t - u_{t-1}| + b \quad (1)$$

де z_t, z^* — поточна й задана висота, м (перший член тримає висоту); $v_{z,t}$ — вертикальна швидкість, м/с (не дає «пружинити»); u_t, u_{t-1} — тяга на поточному й попередньому кроці

(не дає смикати мотори); $w_z = 1,00$, $w_v = 0,20$, $w_u = 0,05$ — ваги штрафів; $b = 0,10$ — бонус за життя за кожен крок, на якому епізод не обірвався. Без нього всі складові від’ємні й апарату вигідно швидко впасти.

Один крок циклу триває 0,02 с модельного часу. Епізод завершується після вичерпання часу (8 с = 400 кроків) або достроково, якщо апарат упав ($z < 0,05$ м) чи вилетів за межі зони ($|z - z^*| > 1,0$ м). Епізоди мають різну довжину, тому всюди беремо *нормовану* віддачу — суму винагород, поділену на тривалість епізоду в секундах (ідеальному висінню відповідає +5,0).

Крива навчання не монотонна й має характерні фази. Одна крива нічого не доводить: за бюджету 500 тис. кроків запуски з різними seed розходяться на 1–2 одиниці.

Кроки навчання	Що робить апарат	Нормована віддача
0–50 тис.	падає одразу, епізод 0,5 с	≈ -8
50–200 тис.	тримається ≈ 1 с	до -3
200–500 тис.	«пружинить» на ± 25 см	$-1,0 \dots -0,4$
0,5–1 млн	тримає ± 8 см	$+2 \dots +4$
1–2 млн	тримає $\pm 2 \dots 3$ см	плато $+4,5$

Корисні посилання для ознайомлення:

- [Stable-Baselines3 documentation](#) — реалізація PPO, яку використовуємо;
- [Schulman та ін. Proximal Policy Optimization Algorithms](#) — оригінальна стаття про PPO;
- [Gymnasium](#) — інтерфейс середовища;
- [Henderson та ін. Deep RL that Matters](#) — чому одна крива нічого не доводить.

Порядок виконання

1. **[разом]** Підготувати середовище: Python 3.10+, gym-pybullet-drones 2.0+, stable-baselines3 2.0+, PyTorch 2.0+, tensorboard 2.13+, NumPy, Matplotlib.
2. **[разом]** Сформулювати задачу висіння як задачу навчання з підкріпленням: описати простір спостережень (дев’ять чисел), простір дій (одне число $u \in [0; 1]$) і функцію винагороди за формулою (1). Обґрунтувати кожну компоненту: чому подається похибка $z - z^*$, а не сама висота; чому дія одна, а не чотири; що штрафует кожен із трьох членів і навіщо потрібен бонус за життя b .
3. **[А]** Реалізувати середовище, сумісне з інтерфейсом Gymnasium: крок 0,02 с (50 Гц), епізод 8 с (400 кроків), дострокове завершення за умовами $z < 0,05$ м або $|z - z^*| > 1,0$ м, обчислення нормованої віддачі. Перевірити середовище пробним навчанням на 2000 кроків: воно має відпрацювати без помилок за 1–2 хвилини (літати політика після такого бюджету ще не вміє).
4. **[В]** Навчити політику алгоритмом PPO на бюджеті 500 тис. кроків, ціль $z^* = 1,0$ м. Мережа — два шари по 64 нейрони, learning rate $3 \cdot 10^{-4}$, seed 0. Передбачити ведення журналу, щоб хід навчання було видно в TensorBoard за середньою віддачею й середньою довжиною епізоду. Зафіксувати крок, на якому довжина епізоду вперше досягла максимуму, і крок, на якому нормована віддача вперше стала додатною. Навчання триває 15–40 хвилин.

5. [С] Оцінити навчену політику без дослідження (детерміновані дії) на 20 епізодах з фіксованим $\text{seed} = 100$. Увести критерій успіху: епізод успішний, якщо він не обірвався достроково і середня $|z - z^*|$ за останні 2 с не перевищує 0,10 м. Обчислити чотири показники з очікуваними діапазонами: середню нормовану віддачу ($+2 \dots +4$), частку успішних епізодів ($0,6 \dots 0,9$), середню $|z - z^*|$ за останні 2 с ($0,03 \dots 0,10$ м) і середню тягу u на плато ($0,55 \dots 0,59$). Частка успішних нижче 0,3 за додатної віддачі означає, що політика збирає бонус за життя, не виконуючи задачі.
6. [В] Повторити навчання тричі, змінюючи лише seed (значення 0, 1, 2) і не змінюючи жодного іншого параметра. Побудувати всі три криві на одному графіку: по горизонталі кроки навчання, по вертикалі нормована віддача. Середнє показати суцільною лінією, а діапазон від мінімуму до максимуму напівпрозорою смугою. Для кожного seed навести пару чисел «віддача, частка успішних». Якщо різниця між найкращим і найгіршим запуском перевищує 2 одиниці, вказати фазу, на якій криві розійшлися.
7. [С] Оцінити PID-регулятор із роботи №1 на тих самих 20 епізодах і з тими самими початковими станами. Порівняти його з навченою політикою за трьома показниками: середня $|z - z^*|$ за останні 2 с, час входження в коридор $\pm 0,10$ м і середня зміна керування $|u_t - u_{t-1}|$. За точністю PID виграє (одиниці сантиметрів проти 3–10 см), за гладкістю результати будуть близькі. Головна різниця в ціні: PID налаштовують трьома числами, а політику навчають за сотні тисяч кроків симуляції.
8. [С] Записати один епізод з увімкненою графікою у відеофайл: має бути видно зліт і вихід на задану висоту. Долучити три кадри із зазначенням модельного часу: старт, перехідний процес і усталене висіння.
9. [разом] Проаналізувати результати: форма кривої навчання, розкид між seed , у чому політика програє PID. Зробити висновки — 3–5 перевірюваних тверджень із числами.

Вимоги до здачі та захисту

Бригада здає репозиторій, у якому: код запускається однією командою з **README**; наведено криву навчання базового запуску з позначеними фазами, графік трьох кривих зі смугою розкиду й чотири показники оцінювання; є таблиця порівняння з ПІД-регулятором і три кадри з відео; у **README** зазначено, хто що робив, із посиланнями на коміти.

Історія комітів має показувати внесок кожного учасника. Робота, зроблена одним за трьох, оцінюється як робота одного.

На захисті питання ставляться персонально: учасник А пояснює склад спостереження й умови завершення епізоду, учасник В — фази кривої навчання й розкид між зернами, учасник С — чому висока віддача сумісна з низькою часткою успішних епізодів.

Висновки подають трьома-п'ятьма перевірюваними твердженнями з числами.

Контрольні запитання

1. Які дев'ять чисел подаються в політику? Чому похибка $z - z^*$, а не z ?
2. Чому політика видає одне число, а не чотири сигнали на мотори?
3. Що фізично означають $u = 0$; $u = 0,57$; $u = 1,0$ для апарата масою 33 г?
4. Поясніть чотири члени формули (1). Що станеться без бонусу b ?
5. Скільки кроків містить епізод 8 с за частоти 50 Гц і яка максимальна віддача?

6. Опишіть фази кривої навчання. Як видно, що навчання застрягло на першій фазі?
7. Що саме змінює seed і чому результат не можна подавати однією кривою?
8. Політика має високу віддачу, але низьку частку успішних епізодів. Чому?
9. За якими трьома показниками порівнюють політику з PID?